

Social media data analysis & real world cases

Nikos Tsirakis

9/12/2017

Agenda

1. Introduction to News & Social Media, Reputation Management Platforms
2. Data, Data, Big Data
3. Analyse, Transform, Enhance, Present
4. Challenges
5. Technologies
6. Case Study
7. Q & A

Introduction

Brandwatch

Mention

Sysomos

Nuvi

Talkwalker

Agorapulse

Lithium

Synthesio

Trackur

Keyhole

Buzzlogix

Mentionlytics

Mediatoolkit

Digimind

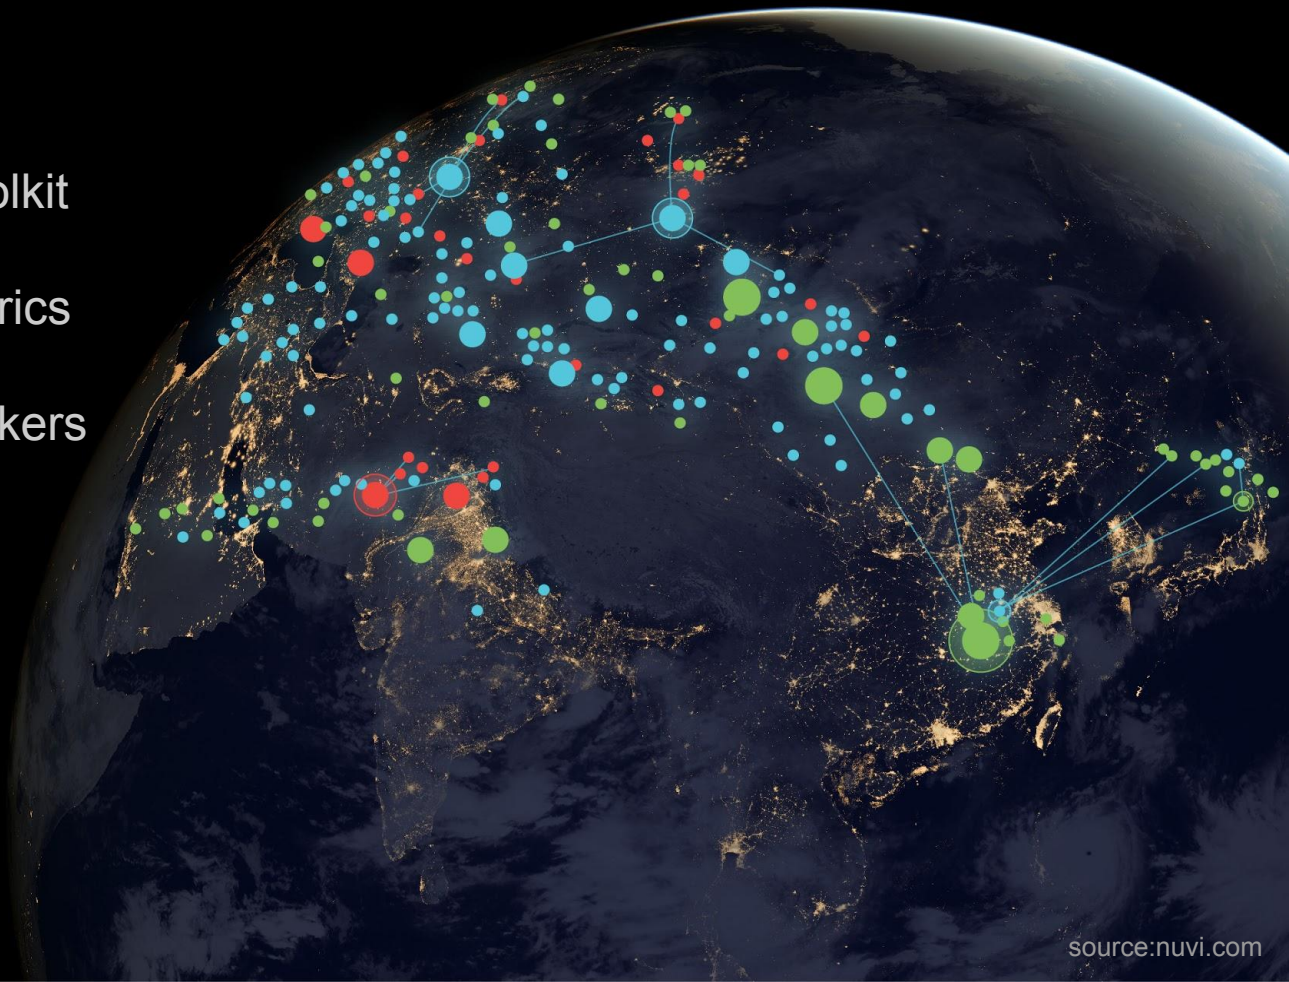
Ubermetrics

Brand24

Socialbakers

Sprinklr

...

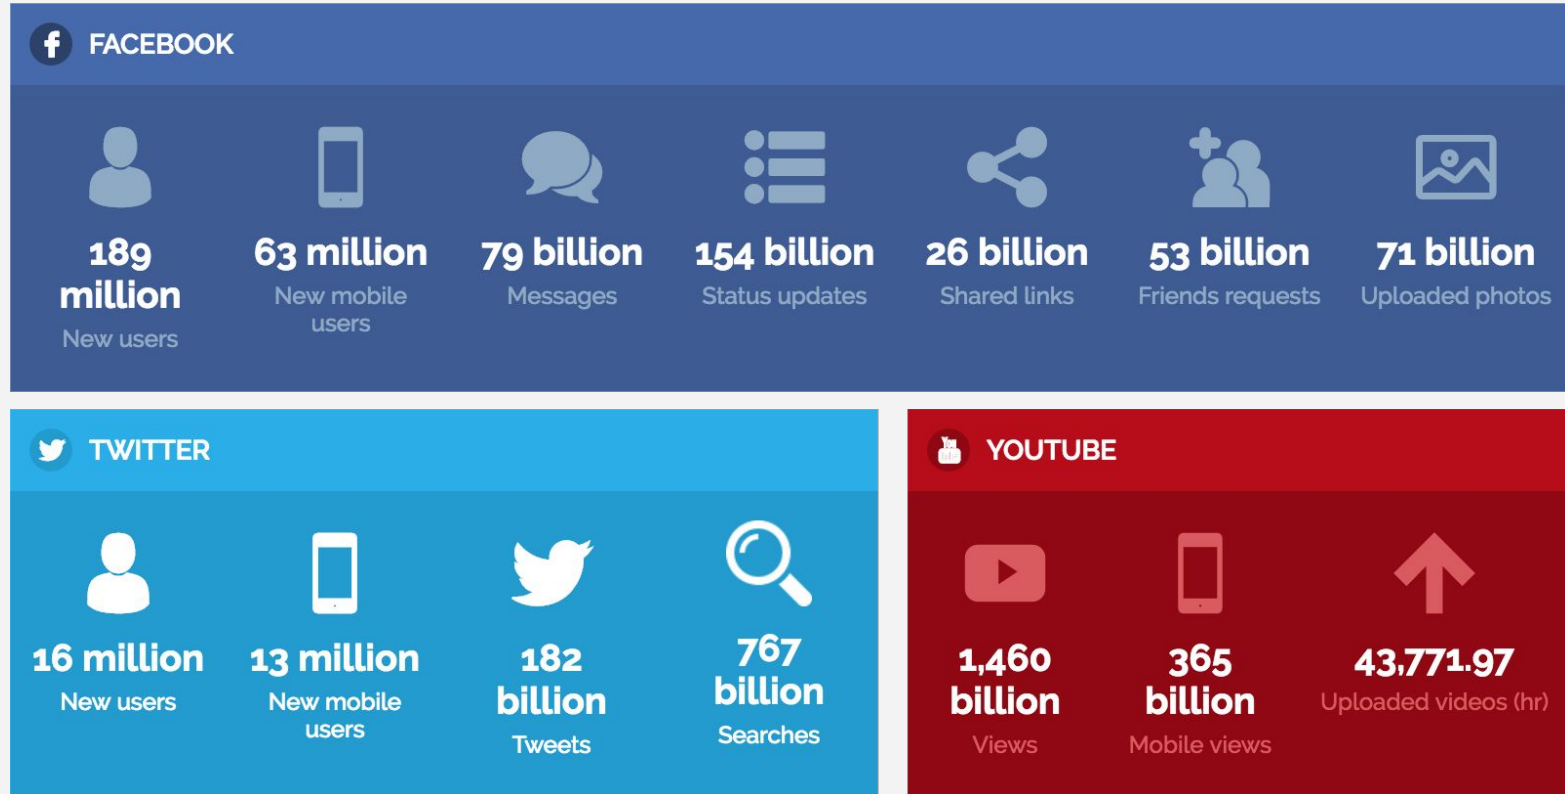


GR Data & Precision in Numbers

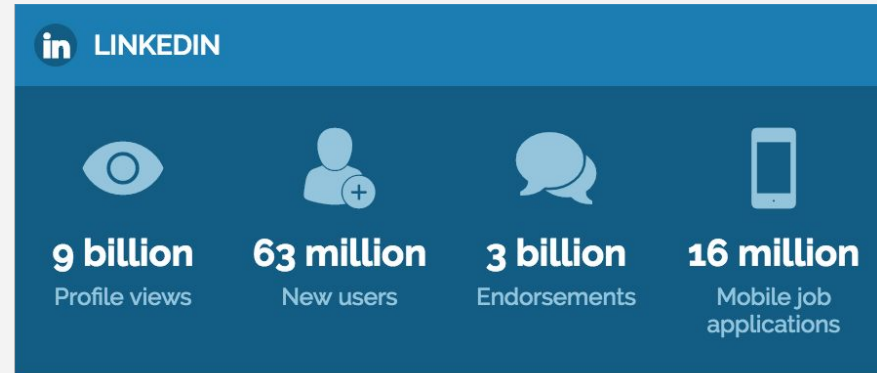
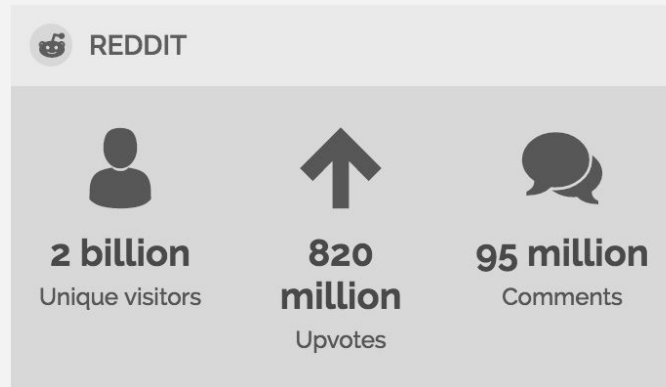

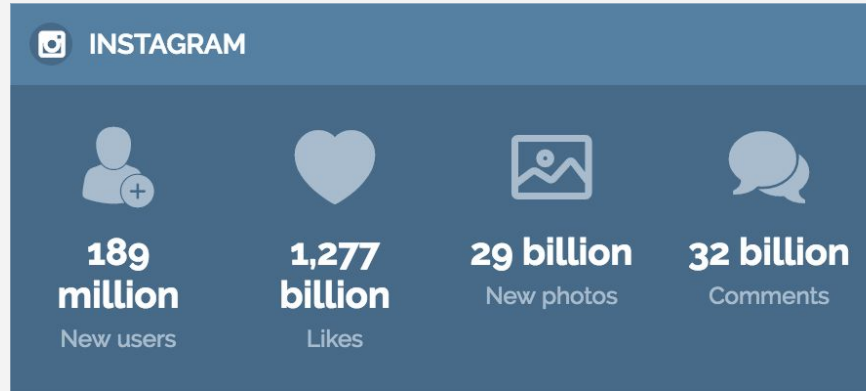
- ~20k news sites & blogs
- +20 popular forums
- ~700k twitter users
- ~5m facebook users
- ~2.1m instagram users (mostly between 18-24)
- ~0.5m articles/d (news, blogs, twitter, facebook, youtube, forums)
- ~7.0m internet users
- ~1 million entities
- ~3 million entity terms
- Sentiment:
 - ~87% in sentence level
 - ~70% in entity level
- NER
 - ~70% with 60% recall



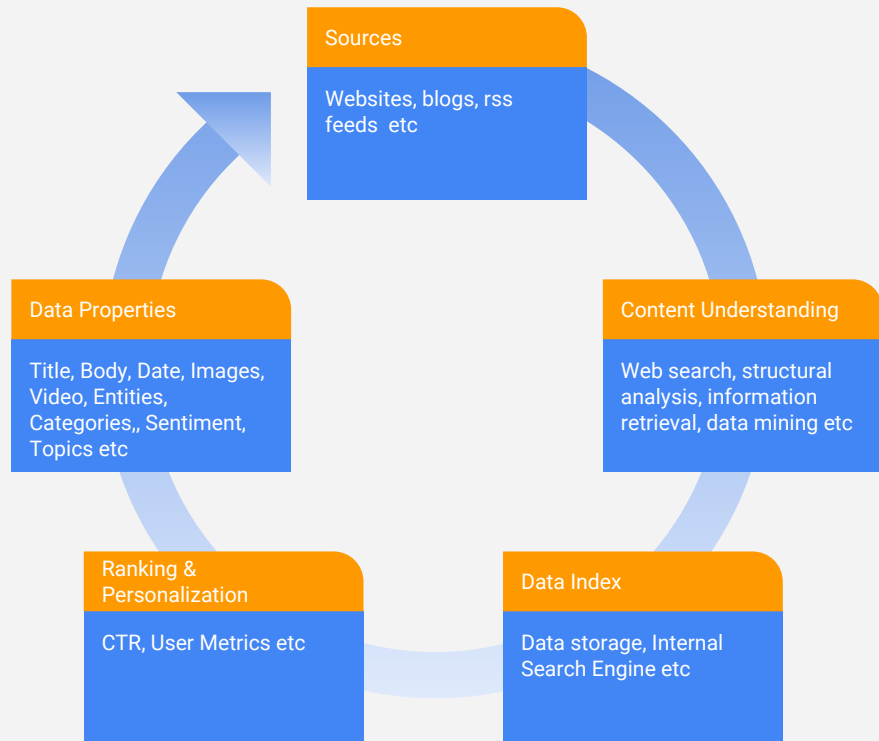
Social Media in numbers (1 year period)



Social Media in numbers (1 year period)




Content Lifecycle



Data Collection




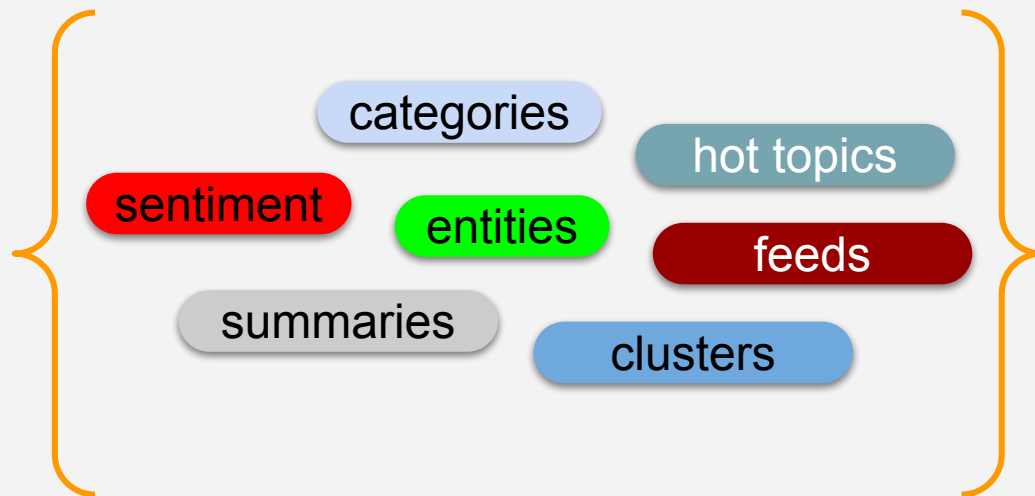

- Web-page Crawlers (xpath queries, regex)
 - News Detection Content
 - ...
- Blogs APIs
 - Blogger
 - Wordpress
 - Medium
 -
- Forum Crawlers
 - PHPBB
 - vBulletin
 -





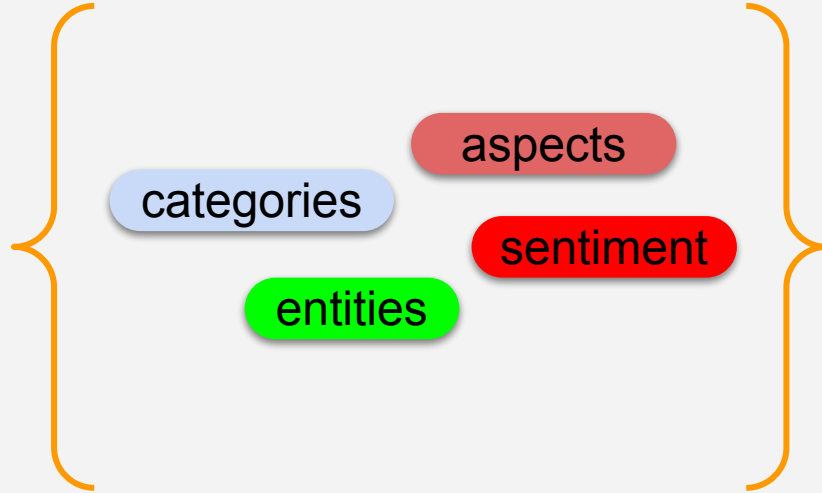
- Social Media Streams
 - Twitter, Facebook ...
- Social Media APIs
 - Twitter, Facebook, Youtube, Instagram
 - ...
- Third Party Services
 - Amazon Alexa
 - Datasift
 - ...
- Linked Data
 - DBpedia, Google Relation Extraction Corpus



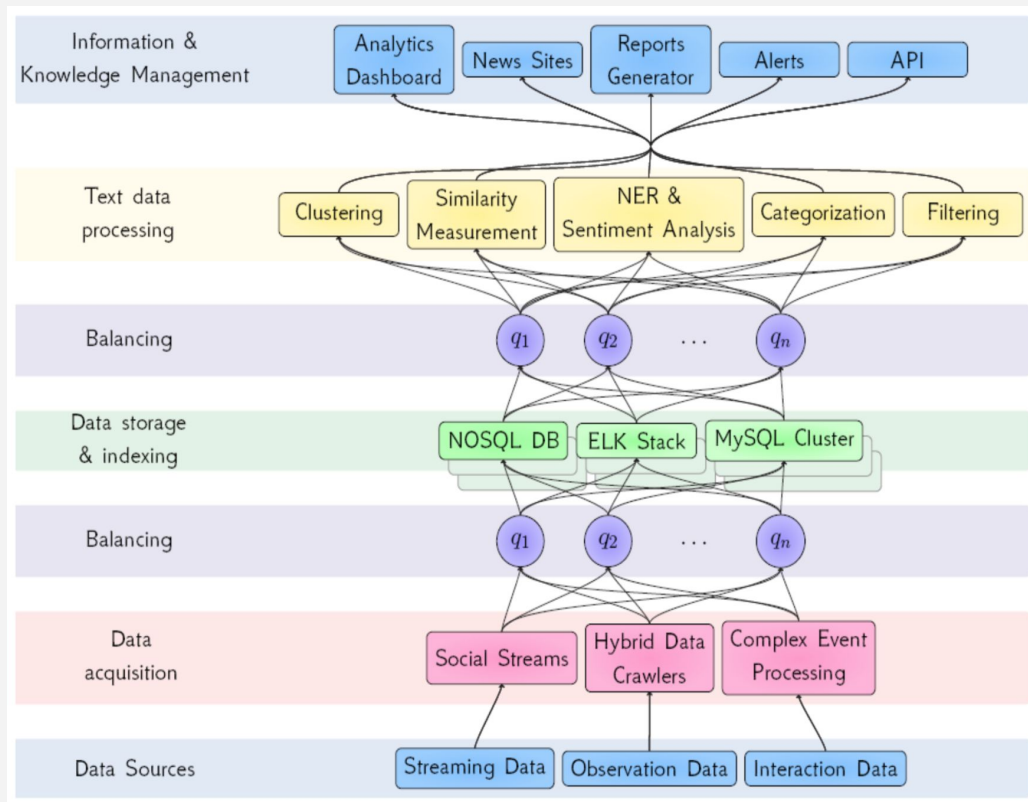
News Content



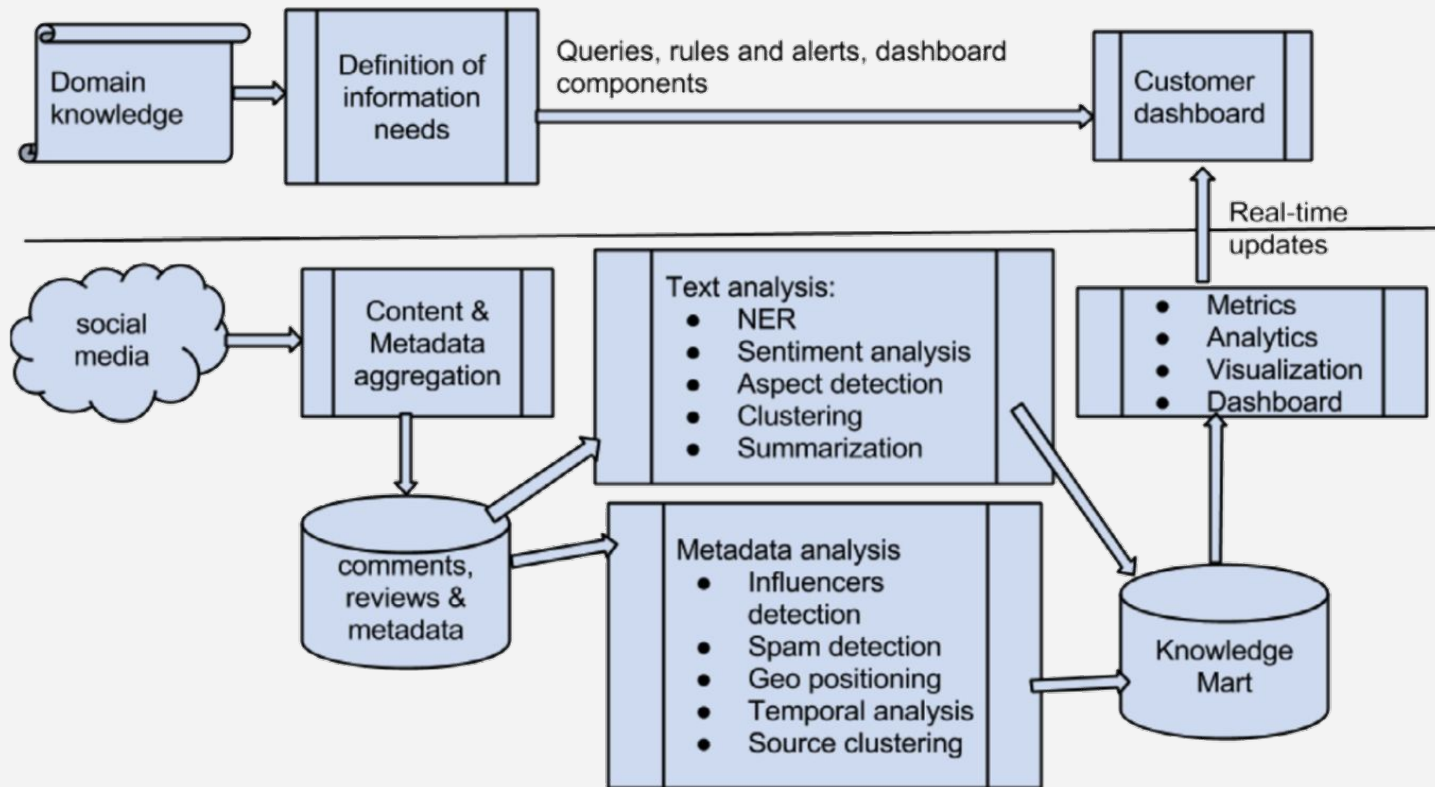
Social Media Content



Architecture



Information Flow



Challenges (I)

ΕΛΛΑΔΑ Τοπικά Κόσμος Οικονομία Αθλητισμός Ψυχαγωγία Επιστήμη Γυναικα Αυτοκίνητο Άντρας Χρήσιμα

Hot topics Sites Blogs ΜΕΡΙΣΜΑ ΑΙΤΗΣΗ | ΣΑΟΥΔΙΚΗ ΑΡΑΒΙΑ | ΜΕΓΚΑΝ ΜΑΡΚΑ | SPD ΣΥΝΑΣΠΙΣΜΟΥ | ΤΣΙΠΡΑΣ ΚΑΜΜΕΝΟΣ

Όλες οι αναφορές για τους υπουργούς στο διαδίκτυο τελευταία 24ωρο

Όλα Sites Blogs Απόψεις

Υπουργός	Απόψεις
Απόστολ	171
Απόστολ	65
Απόστολ	55
Απόστολ	30
Απόστολ	26
Απόστολ	14
Απόστολ	9

Τα Σημαντικότερα τώρα

Κόντρα στη Βουλή: Νεύρα, ειρωνεία, απειλές και καμία απάντηση

Ήταν μια συζήτηση όχι όπως μερικοί Συναξισμοί έπαισαν να την χαρακτηρίσουν ως "μητέρα των μαχών", αλλά ως "μητέρα των λασπών". Κάθε είδους λασπη εκτοξεύτηκε προτού ακόμα αρχίσει η συζήτηση στην Ολομέλεια. Κάποιες εκφράσεις του Πάνου Καμμένου ότι θα τους "ξεσκιάσει" ή θα τους "ξεσκεπάσει" ή ακόμα...

in.gr

160 Ειδήσεις 16 Blogs 3 Απόψεις 150 Πολυμέσα Σχόλια

Ελλάδα Οι σημαντικότερες ειδήσεις

Κόντρα στη Βουλή: Νεύρα, ειρωνεία, απειλές και καμία απάντηση

Ήταν μια συζήτηση όχι όπως μερικοί Συναξισμοί έπαισαν να την χαρακτηρίσουν ως "μητέρα των μαχών", αλλά ως "μητέρα των λασπών". Κάθε είδους λασπη εκτοξεύτηκε προτού ακόμα αρχίσει η συζήτηση στην...

in.gr

160 Ειδήσεις 16 Blogs 3 Απόψεις 150 Πολυμέσα Σχόλια

Ροή ειδήσεων Ροή λέξεων

Θλάση στον αριστερό προσαγωγό ο Τσάσις
Πριν από 32 λεπτά

Κάνει... μάγια (video)
Πριν από 32 λεπτά

Έφηβος τύχανιστής σχεδιάζε επίθεση σε συναυλία του Τζάστιν Μπίμπερ
Πριν από 32 λεπτά

Βροχές και καταγίδες την Τρίτη - Χιόνια στα ορεινά
Πριν από 44 λεπτά

Γενική απεργία στις 14 Δεκεμβρίου αποφασίζει η ΓΣΕΕ
Πριν από 44 λεπτά

Share this Όλα τα widgets

Δημοφιλή

Η δημοκρατική επιβολή του Τσίπρα
Πριν από 15 ώρες, 19 λεπτά

Ποινική δίωξη στον πρώην πρόεδρο της ΕΡΟ Βασίλη Γκαγκάση για κακοδουνηματική απιστία
Πριν από 59 λεπτά

Ανατίναξαν ΑΤΜ στα Καλύβια Αττικής
Πριν από 8 ώρες, 58 λεπτά

Αναζητείται άκατονο κατάστημα!
Πριν από 14 ώρες, 48 λεπτά

Η Εσφά λέει αυτά που κρύβει η ΝΔ
Πριν από 15 ώρες, 11 λεπτά

Hot topics

Top News / Breaking News

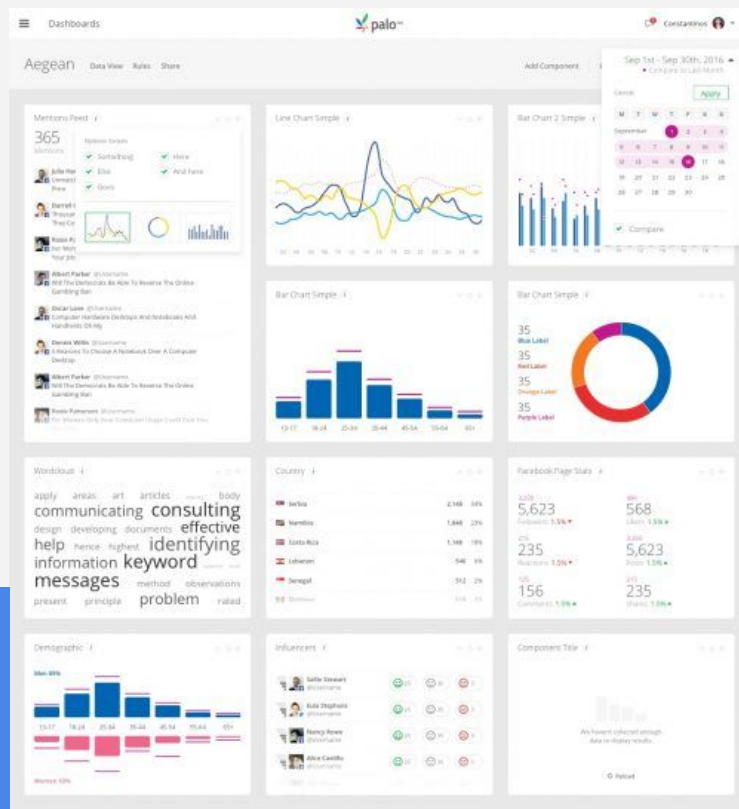
Clustering

Personalized Popular

Challenges (II)

- Poor Content (outdated stories, missing media etc)
- Wrong Format (misspelling, wrong media etc)
- Legal Issues (copyright, plagiarism etc)
- Topic evolution (sport games, breaking news etc)
- Cluster Size (big news in short period etc)

Version 1.0




Technologies

Scale-out



VS

Scale-up



Technologies to scale up

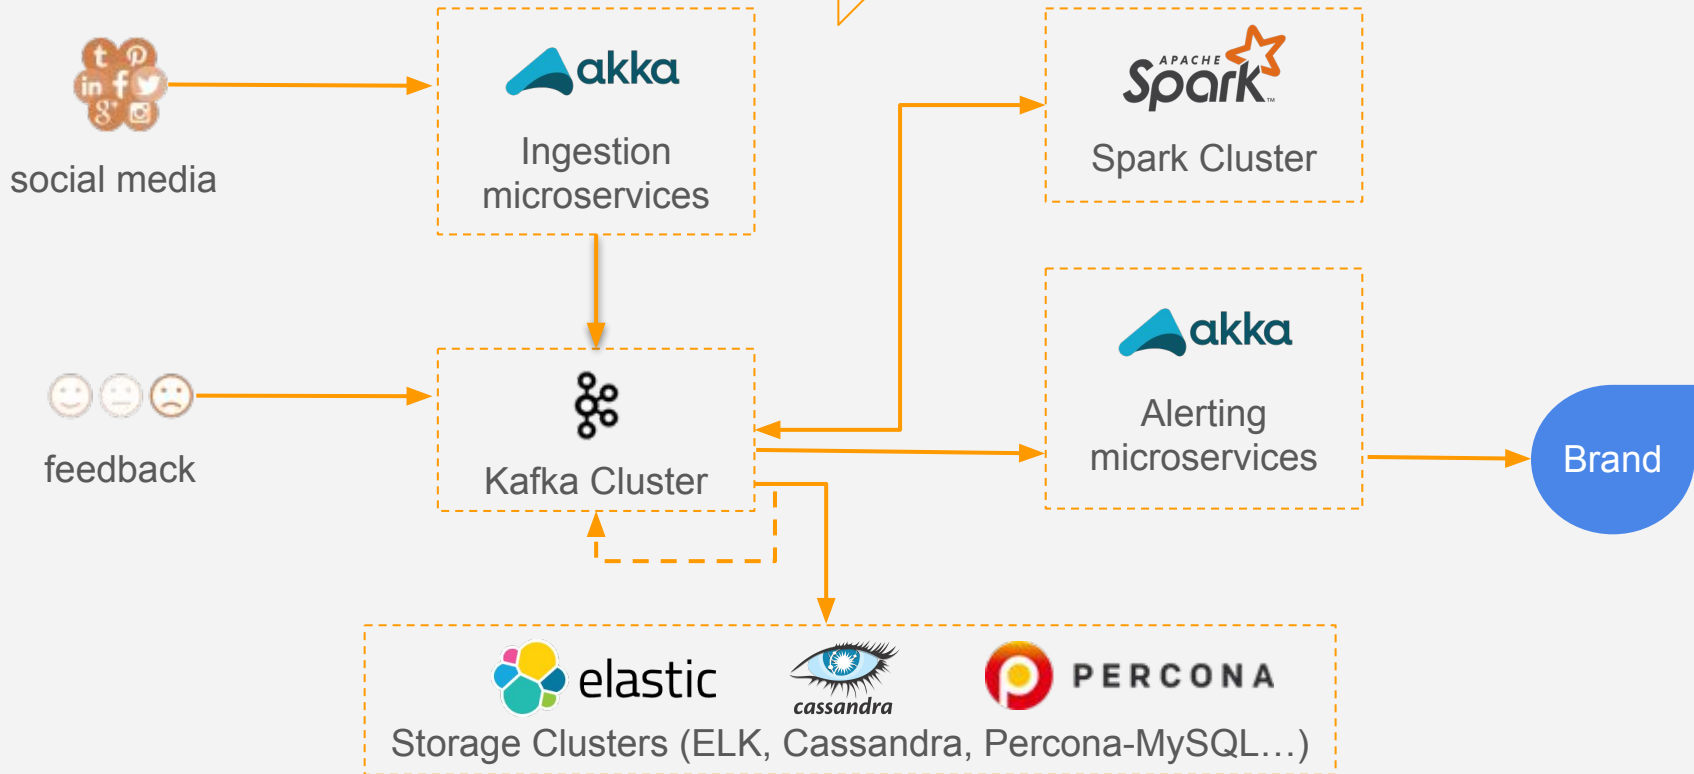
Java & Python threaded services

RDBMS (MySQL)

Search (Solr)



Technologies to scale out



Case Study - Hands On



twitter



logstash



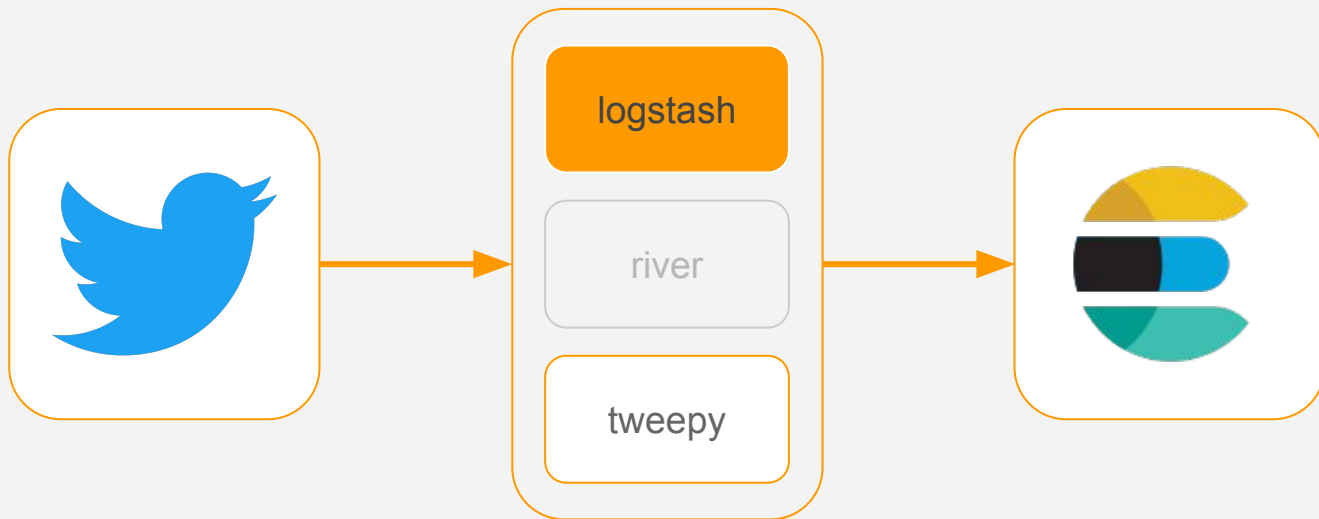
elasticsearch



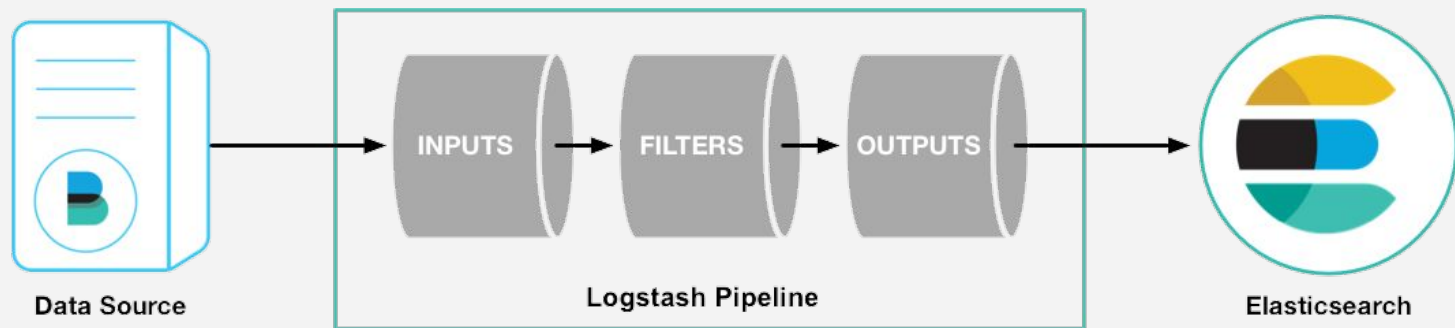
kibana

Ways to get data

- Logstash
- ~~Elasticsearch-twitter-river~~ (March 2015 - **deprecated** due to cluster stability)
- Tweepy



The Logstash Pipeline



Add a filter +


Total Tweets

Count


10,114

Count


Tweets vs. time



Top 10 hashtags



Popular Hashtags



Geo Count



Top 10 influencers (by retweet volume)

retweeted_status.user.screen_name: Descending	Max retweeted_status.favorite_count
JohnStam13	5,382
fayskorda	4,680
manoskrt	4,196
vasilis_tag	3,603
tsipouridhs	3,198
KaterinaGreece2	2,471
vigeke	2,437
FKatsakis	2,414
stef_an	2,284
CheapEripo	2,128

Popular Hashtags per hour





Questions?

[@tsirakis](#)